

Benchmark 次要指标与重叠感知的配对检验 (v1)

2026-10-01。只读取已提交的 B2/B3/B3noREV/B4 逐种子 CSV 与固定版本的 11 个作者模型 CSV，不重跑任何模型，也不改参数。脚本: `python -m evals.benchmark_stats_v1`; 结果: `benchmark/results/benchmark_stats_v1.json`。

为什么要校正

随机拆分的 100 个种子从同一数据集各抽 20% 作外层测试集，测试集彼此重叠，逐种子差值并不独立。朴素 Wilcoxon 检验把它们当成 100 个独立样本，p 值会严重偏小。这里另报 Nadeau-Bengio 校正的重复抽样 t 检验：方差乘以 $1/J + n_{\text{test}}/n_{\text{train}}$ ($J=100$, $n_{\text{test}}/n_{\text{train}}=0.25$)。弱相关拆分的 100 个种子复用同一个外层留出集，任何泛化检验都没有意义，只报告描述性数值。

配对 NS-AUC 检验

比较（随机拆分）**B4 - B2** · **+0.2231**

- 配对胜场: 100/100
- 朴素 Wilcoxon p: 3.9e-18
- Nadeau-Bengio 校正 p: 0.000
- 校正 95% CI: [+0.1812, +0.2649]

比较（随机拆分）**B4 - BNNR** · **+0.0122**

- 配对胜场: 87/100
- 朴素 Wilcoxon p: 5.9e-13
- Nadeau-Bengio 校正 p: 0.066
- 校正 95% CI: [-0.0008, +0.0251]

比较（随机拆分）**B4 - MBiRW** · **+0.0471**

- 配对胜场: 95/100
- 朴素 Wilcoxon p: 7.3e-17
- Nadeau-Bengio 校正 p: 0.005
- 校正 95% CI: [+0.0145, +0.0797]

比较（随机拆分）**B3 - B2** · **+0.2011**

- 配对胜场: 100/100
- 朴素 Wilcoxon p: 3.9e-18
- Nadeau-Bengio 校正 p: 0.000
- 校正 95% CI: [+0.1675, +0.2348]

比较（随机拆分）**B3 - BNNR** · **-0.0097**

- 配对胜场: 35/100

- 朴素 **Wilcoxon p**: 7.4e-03
- **Nadeau-Bengio** 校正 **p**: 0.591
- 校正 **95% CI**: [-0.0455, +0.0261]

比较 (随机拆分) **B3 - MBiRW · +0.0252**

- 配对胜场: 76/100
- 朴素 **Wilcoxon p**: 4.4e-09
- **Nadeau-Bengio** 校正 **p**: 0.168
- 校正 **95% CI**: [-0.0108, +0.0613]

更正: B4 比 BNNR 高 +0.0122, 但校正后 $p = 0.066$, 95% CI [-0.0008, +0.0251] 跨零。随机拆分上 B4 的均值排第一, 但与 BNNR 的差异在校正检验下不显著, 应表述为 “与最强发表模型持平、均值略高”。B4 相对 MBiRW 与 B2 的优势在校正后仍显著。B3 与 BNNR、MBiRW 的差异均不显著。

次要指标 (**100** 种子均值)

随机拆分:

模型 **B4 · 0.745**

- **global AUC**: 0.953
- **global NDCG**: 0.467
- **HR@10**: 0.014
- **training time (s)**: 191

模型 **B3 · 0.723**

- **global AUC**: 0.950
- **global NDCG**: 0.559
- **HR@10**: 0.042
- **training time (s)**: 13

模型 **BNNR · 0.733**

- **global AUC**: 0.954
- **global NDCG**: 0.657
- **HR@10**: 0.080
- **training time (s)**: 808

模型 **MBiRW · 0.698**

- **global AUC**: 0.951
- **global NDCG**: 0.424
- **HR@10**: 0.009
- **training time (s)**: 2371

模型 **HAN · 0.598**

- **global AUC:** 0.905
- **global NDCG:** 0.370
- **HR@10:** 0.001
- **training time (s):** 218

模型 LogisticMF · 0.670

- **global AUC:** 0.949
- **global NDCG:** 0.480
- **HR@10:** 0.017
- **training time (s):** 8

模型 B2 · 0.522

- **global AUC:** 0.945
- **global NDCG:** 0.461
- **HR@10:** 0.019
- **training time (s):** 4

弱相关拆分:

模型 B4 · 0.658

- **global AUC:** 0.931
- **global NDCG:** 0.435
- **HR@10:** 0.036
- **training time (s):** 148

模型 B3 · 0.692

- **global AUC:** 0.936
- **global NDCG:** 0.431
- **HR@10:** 0.024
- **training time (s):** 13

模型 BNNR · 0.606

- **global AUC:** 0.925
- **global NDCG:** 0.421
- **HR@10:** 0.027
- **training time (s):** 939

模型 MBiRW · 0.738

- **global AUC:** 0.941
- **global NDCG:** 0.424
- **HR@10:** 0.014
- **training time (s):** 2630

模型 HAN · 0.703

- **global AUC:** 0.937
- **global NDCG:** 0.359
- **HR@10:** 0.001
- **training time (s):** 246

模型 **LogisticMF** · **0.658**

- **global AUC:** 0.929
- **global NDCG:** 0.370
- **HR@10:** 0.001
- **training time (s):** 8

模型 **B2** · **0.502**

- **global AUC:** 0.897
- **global NDCG:** 0.345
- **HR@10:** 0.012
- **training time (s):** 4

- 主指标之外 **BNNR** 更强: 随机拆分的 global NDCG (BNNR 0.657, B4 0.467) 和 HR@10 (0.080 对 0.014) 都明显高于 B4。B4 的优势只体现在逐药物行的 NS-AUC 上; global AUC 各强模型都在 0.95 左右, 区分度低。
- 训练时间不可直接比较: BNNR 与 MBiRW 是作者环境中的 Octave 运行时间; B4 使用本项目的 NumPy BNNR 移植, 并启用了逐折精确结果缓存。这里只能说明 B3 (约 13 秒/种子) 远快于矩阵补全类方法。
- 弱相关拆分上 MBiRW 在 NS-AUC 上仍领先 B4 与 B3 (100/100 种子), 但这是同一个留出集的重复测量。