

LLM 知识污染探针 (TRANSCRIPT, v1)

运行日期: 2026-09-28。模型: deepseek-flash (DeepSeek beta 端点, strict function calling, temperature=0)。
运行器: evals/contamination_probe.py; 聚合结果: benchmark/results/contamination_probe_v1.json (只含聚合数字、样本哈希、调用计数和成本估计, 不含原始 prompt/response)。每次模型请求都由 TraceRecorder 单独写入带 SHA-256 链的 trace (位于被忽略的 artifacts/contamination_probe/provider_traces/), 入口级 trace 位于 artifacts/contamination_probe/traces/。

目的

检验“让 LLM 看到药物/疾病名称”时, 它能否凭记忆中的背景知识“找回”TRANSCRIPT 中已知的适应症, 也就是标签泄漏。如果能, 那么任何让模型看到身份信息的基准测得的只是记忆, 不是发现能力。本项目的 benchmark 采用 strict 模式 (LLM 永远看不到药物/疾病身份), 这个实验用来检验这条规则是否必要。

协议

- ID → 名称映射** (先查离线来源): 仓库内的 Repurposing Hub 文件只有 Broad ID、名称、InChIKey 和 PubChem CID, 没有 DrugBank ID 或 MedGen CUI, 仓库里也没有现成对照表, 所以改用公开 API:
 - DrugBank ID → mychem.info drugbank.name (610 个 DB ID);
 - PubChem CID → PubChem PUG REST Title (3 个 CID);
 - MedGen CUI → NCBI E-utilities esearch/esummary (db=medgen) 的 title。映射缓存在 artifacts/contamination_probe/ (被忽略), 覆盖率汇总见 mapping_coverage.json。
- 抽样并冻结** (seed 20260928): 在药物名和疾病名都已映射的配对中, 抽取阳性 (1) 并以 300 为上限随机抽样, 再随机抽取同样数量的未知 (0) 配对, 另外纳入全部 -1 配对。样本在任何模型调用之前写成规范化 JSONL 并记录 SHA-256; 之后每一步都会重新校验哈希, 哈希不同的样本拒绝覆盖。
- 三种条件:**
 - Open-book:** 只问 “Is an approved or established treatment for?”, 要求返回 0-1 概率 (strict JSON 工具调用)。
 - Closed-book:** 不提供任何名称或 ID, 只提供该配对的 Spearman 反转分数 (items.csv 与 users.csv 在 12,096 个基因上的负 Spearman 相关), 以及它在该药物 151 个疾病中的排名百分位, 问同一个概率问题。运行器在发送前会断言请求中不含名称、ID 或标签。
 - 原始反转分数:** 直接用 Spearman 反转分数作为排序分数, 不经过 LLM。
- 指标:** 主指标是阳性 vs 未知的 AUC (Mann-Whitney, 并列按 0.5 计), 用分层 bootstrap (2000 次, seed 20260928) 求 95% CI。open 与 closed 的差值用配对分层 bootstrap。阳性 vs -1 只作描述, 因为 n=11。

结果

映射覆盖率: 药物 611/613 (未映射 DB00510、DB01361), 疾病 150/151 (未映射 C0023473); 阳性 399/401、-1 11/11 的两端名称都已映射。样本: 300 个阳性、300 个未知、11 个 -1, 共 611 对; SHA-256 为 898a59fe00cc1dbcd22a06907737eb723f1b1bbc9c36cc188f59ad422eb4e4b。

条件	AUC (阳性 vs 未知)	95% CI	阳性 / 未知的中位概率	阳性 vs -1 (描述, n=11)
Open-book (看到名称)	0.567	[0.526, 0.609]	0.02 / 0.02	0.516 [0.362, 0.672]
Closed-book (只看反转数字)	0.527	[0.482, 0.570]	0.006 / 0.006	0.481 [0.312, 0.636]
原始 Spearman 反转分数	0.519	[0.475, 0.567]	—	0.489 [0.300, 0.672]
Open – Closed (配对差)	+0.040	[−0.022, +0.102]	—	—

调用量：探针共 1222 次模型调用（611 对 × 2 个条件），全部成功，0 次重试。另有 2 次正式运行前的冒烟调用，不计入上表。共约 56.6 万 token；按 evals/run_planner_eval.py 中的价格表估算，费用为 0.081 美元（off-peak）至 0.162 美元（peak）。

解读

- **Open-book** 的 **AUC** 显著高于 **0.5**（CI 下界 0.526），而 **closed-book** 和原始反转分数的 CI 都包含 0.5。看到名称以后，模型确实从记忆中带进了与标签相关的信号。模型给出的高概率几乎都落在教科书级的适应症上，例如四环素类-痤疮（0.97-0.98）、氟哌啶醇-亨廷顿病（0.85）。这是记忆/泄漏，不是发现：模型没有使用任何表达数据。
- 泄漏幅度比预期小。open 与 closed 的配对差为 +0.04，95% CI 跨过 0（[−0.02, 0.10]）。原因是 TRANSCRIPT 的很多“阳性”并不是常识性的适应症（例如环丙沙星-Wilson 病、克拉霉素-Turner 综合征），模型对这些都给出约 0.02 的低概率。反过来，一些被标为“未知”的配对其实是真实的临床适应症（辛伐他汀-急性心肌梗死、螺内酯-充血性心衰、氨苄西林-链球菌扁桃体炎，概率均为 0.97）。模型的记忆和数据集标签只是部分重合。
- 对 **strict** 模式的意义：即使在这个标签噪声很大的数据集上，名称可见仍然带来了可检测的、与表达信号无关的判别力（open-book 的 CI 排除 0.5，closed-book 与原始反转分数的 CI 不排除 0.5）；但 open 与 closed 的直接配对差在本样本中还没有达到统计显著。在标签更接近教科书适应症的数据集上，这种泄漏只会更大。因此，凡是报告“LLM 辅助药物重定位”的基准，都必须在 LLM 看不到身份信息的 **strict** 模式下运行；open-book 的高分不能当作方法有效的证据。
- Closed-book 的 AUC（0.527）和原始反转分数（0.519）相当，并且只输出 6 种不同的概率值。模型基本上只是把反转数字单调地映射成很低的概率，没有额外的判别能力。

局限

- 未知 ≠ 阴性：0 表示未记录，不表示无效。上面列举的真实适应症被标为 0，会直接压低 open-book 的 AUC，所以 AUC 是“与该数据集标签的一致性”，不是真实准确率。
- -1 只有 11 个，相关的 AUC 只作描述。

- 映射质量: MedGen 的 title 有时是遗传易感性或亚型的条目 (如 “Dermatitis, atopic, 2”、“Influenza, severe, susceptibility to”), 这会削弱 open-book 的识别能力, 所以泄漏量可能被低估。3 个药物/疾病 ID 未映射。
- 只测了一个模型、一种问法, 而且 temperature=0; 换成更强的模型或 few-shot 提问, 泄漏可能更大。
- 阳性从 399 个中随机抽取了 300 个; 未知配对是均匀随机抽取, 没有按药物或疾病匹配。
- Closed-book 的提示里给了约 0.4% 的基准率, 这会把输出概率整体压低, 但不影响 AUC 的排序比较。

复现

```
python -m evals.contamination_probe map      # 映射 (缓存后不再联网)
python -m evals.contamination_probe sample   # 冻结样本; 哈希不同则拒绝覆盖
python -m evals.contamination_probe run      # 需要 .env 中的 DEEPSEEK_API_KEY; 按 checkpoint
↪ 断点续跑
python -m evals.contamination_probe analyze
```