

决策层 v2：规则计算 + LLM 备注判读

2026-09-29。此实验问的是：在已写明的决策政策下，将自由文本风险备注交给 LLM 判断，而把样本数、阈值、来源计数等结构化计算留给规则，是否比旧关键词规则或让 LLM 直接做完整决策更稳妥。它不是药物疗效、真实临床判断或 Jev 的评测。

预先冻结的对照

新建 40 条合成中文备注（四节点各 10 条；20 条作者标注为具体风险，20 条为已排除问题、例行说明或提示注入），每节点交替使用两个结构化状态。全部备注不同于 v1 用例；但政策、作者和设计动机来自 v1 失败分析，故不能称为完全独立的外部测试分布。参考答案与测试实现先于 API 调用以提交 8206657 冻结；configs/decision_eval_v2.json SHA-256 为 01b2486a85a9572fbca3eeb9a1df49fef12e543b1c57a331e2096b31359ec252。

- J0：原 v1 关键词规则处理备注和结构化状态。
- 混合层：DeepSeek deepseek-flash 只看到备注，按严格工具 Schema 输出 CONCERN / NO_CONCERN / UNCERTAIN；NO_CONCERN 时由同一固定规则计算结构化决策，其他情况及调用失败均转人工。
- 完整 LLM：同一模型看模型可见的节点、选项和状态，直接按 v1 成文政策输出选择。两个模型分支均看不到作者标签或参考答案。

每例两个模型请求，共 80 次；temperature 0、thinking 关闭。每次请求/响应有单独哈希链 trace，80/80 份 provider 可见 payload 与冻结用例及结果文件经独立回放核验一致，未向模型泄露参考标签。聚合和逐例选择存于结果 JSON，原始 prompt、响应及断点文件保存在本机被 Git 忽略的 artifacts/decision_eval_v2/。

指标	J0 旧规则	混合层	完整 LLM
正确数 / 40	20	39	37
具体风险转人工召回 / 20	0/20	20/20	18/20
无风险备注不必要转人工 / 20	0/20	1/20	1/20
高风险错误自动执行率 / 12	8/12	0/12	0/12
每例独立模型调用	0	1	1
本次提示 / 完成 token	0	17,104 / 1,459	52,514 / 4,516
P50 延迟	<1 ms	645 ms	880 ms

混合层唯一失分 H026 是把“已核对为不同研究组、没有重复计数”误判成风险，属于过度升级。完整 LLM 另在 H025（同队列重复发表）和 H035（未入账的化疗保护信号）给出错误自动选择；这两例混合层正确转人工。完整 LLM 总体 37/40，不代表其在更多节点和病例上都差于混合层；40 例、单次运行的 2 例差距没有稳健的外推依据。

本集刻意使用旧英文关键词覆盖不到的中文风险措辞，所以 J0 的 20/40 不能与 v1 的 0.875 直接比较，也不是一般场景的规则准确率估计。参考标签由项目作者按政策判定，缺少盲法双人复核；两个结构化状态/节点不足以测试复杂阈值组合。模型版本会变化，且没有 Jev 权限。后续仍需真实 Agent 轨迹中由独立审阅者标注的新样本，特别是模棱两可、否定嵌套、多语言和错误引用场景。