

Jev 实测：决策层对比（v1 120 例 · v2 40 例）

2026-10-01。Jev 通过 OpenCode Zen 调用（<https://opencode.ai/zen/v1/systemone>，模型 jev-1.13-free）。付费版 jev-1.13 因账户余额不足返回 HTTP 402，在得到任何答案前改用限时免费版，修订已单独提交。两组用例、策略文本和门控阈值（低风险 0.8 / 高风险 0.9）都在调用前冻结，与 LLM 层完全相同。结果：benchmark/results/decision_eval_v1_jev.json、benchmark/results/decision_eval_v2_jev.json；汇总：benchmark/results/jev_evaluation_summary.json（python -m evals.summarize_jev_evaluation）。

v1：120 个封闭决策用例

决策层	准确率	模糊用例转人工	升级率	高风险误执行
J0 固定规则	0.875	0.688	0.225	0.033
J1 flash	0.875	1.000	0.283	0.150
J1 v4-pro	0.883	1.000	0.292	0.133
J2 Jev（无门控）	0.900	0.938	0.258	0.117
J3 flash + 门控	0.792	1.000	0.400	0.083
J3 v4-pro + 门控	0.883	1.000	0.292	0.133
J3 Jev + 门控	0.783	1.000	0.483	0.000
J4 Jev + 门控 + LLM 兜底	0.867	1.000	0.342	0.067

校准与速度	flash	v4-pro	jev
多分类 Brier（越低越好）	0.221	0.228	0.147
ECE（10 箱，越低越好）	0.025	0.107	0.042
证据充分性 noul	1.000	0.955	1.000
AUROC			
数据质量评分	0.868	0.894	0.929
Spearman			
单次延迟 P50（ms）	896	1775	1048
门控拦下的低置信判断	29/120	0/120	32/120

v2：40 条中文风险备注

方案	正确 / 40	高风险误执行	风险备注转人工	无风险备注误转人工
J0 旧规则	20	0.667	0.000	0.000
混合 · flash 判备注	39	0.000	1.000	0.050
混合 · v4-pro 判备注	38	0.000	1.000	0.100

方案	正确 / 40	高风险误执行	风险备注转人工	无风险备注误转人工
混合 • Jev 判备注	39	0.000	1.000	0.050
混合 • Jev + 置信门控	33	0.000	1.000	0.350
完整 flash	37	0.000	0.900	0.050
完整 v4-pro	37	0.167	0.850	0.000
完整 Jev	32	0.083	0.900	0.050

结论

- **Jev 准确率最高、Brier 最低**：不加门控时准确率 0.900，高于规则与两个 DeepSeek 模型；Brier 0.147 明显低于 flash（0.221）与 v4-pro（0.228）。但单看校准误差 ECE，flash（0.025）略好于 Jev（0.042），v4-pro（0.107）最差，所以不能说 Jev 在所有校准指标上都最好。数据质量评分的 Spearman 以 Jev 最高（0.929）。
- **Jev + 门控把高风险误执行降到 0**（flash + 门控为 0.083，v4-pro 门控从不触发），代价是升级率升至 0.483。J4 把低置信判断交给 flash 后，准确率回到 0.867，高风险误执行 0.067，介于两者之间。
- **混合设计对判断器不敏感**：v2 中“规则算结构化字段、模型只判备注”的混合层，无论 flash、v4-pro 还是 Jev 判备注，高风险误执行都是 0（Jev 39/40）。
- **让模型包办整个决策不稳**：完整 Jev 只有 32/40，且出现高风险误执行；完整 v4-pro 也出现了。这再次支持“模型只做封闭的窄判断”的分工。
- 给混合层再叠加置信门控会过度保守（无风险备注 0.350 被转人工），不建议在 v2 这类备注判断上使用。
- 延迟：Jev 单次约 1048 ms，与 flash 相近，明显快于 v4-pro。免费模型，未计成本。
- 局限：用例为按成文策略生成的合成数据，每组一次运行；免费版模型可能与付费版不同。