

换模型复现：deepseek-flash 对 deepseek-v4-pro

2026-10-01。把四组已冻结的 LLM 评测在 deepseek-v4-pro 上原样重跑：测试用例、提示词、评分规则都不变，原 flash 结果不覆盖。脚本：python -m evals.summarize_model_replication；汇总：benchmark/results/model_replication_v4_pro.json。两者属于同一厂商、同一模型系列，结论不能推广到其他厂商的模型。源文件里的成本估算都按 flash 的价格表计算，因此不做成本比较。

评测	指标	deepseek-flash	deepseek-v4-pro
规划器 v3 holdout (100 例)	正确	98/100	97/100
决策层 v1 (120 例)	平均延迟	870 ms	1918 ms
	J1 准确率	0.875	0.883
	J1 高风险误执行	0.150	0.133
	J1 Brier	0.221	0.228
	J3 (加门控) 高风险误执行	0.083	0.133
决策层 v2 (40 例)	门控拦下的低置信判断	29/120	0/120
	混合层正确 / 高风险误执行	39/40 / 0.000	38/40 / 0.000
	完整 LLM 正确 / 高风险误执行	37/40 / 0.000	37/40 / 0.167
污染探针 (600 对)	开卷 AUC [95% CI]	0.567 [0.526, 0.609]	0.542 [0.503, 0.582]
	闭卷 AUC	0.527	0.518
	开卷 - 闭卷 [95% CI]	+0.040 [-0.022, +0.102]	+0.024 [-0.030, +0.078]

结论

- 规划能力不依赖具体模型：两者在 100 例冻结 holdout 上分别为 98 与 97，差距在一两例之内；v4-pro 延迟约为 flash 的 2.2 倍。
- 置信门控的阈值不能跨模型照搬：flash 有 29 个低置信判断被门控转人工，高风险误执行从 0.150 降到 0.083；v4-pro 的 120 个判断全部高于阈值，门控一次都没触发，J3 与 J1 完全相同。两者 Brier 相近，说明 v4-pro 并没有更准，只是更自信。
- 混合设计在两个模型上都安全：决策层 v2 中“规则算结构化字段、LLM 只判备注”的混合层，在两个模型上高风险误执行都是 0；让 LLM 包办全部决策时，v4-pro 出现 17% 的高风险误执行，flash 为 0。
- 更强的模型并没有泄漏更多：v4-pro 开卷 AUC 为 0.542，略低于 flash 的 0.567，置信区间仍刚好高于 0.5；两者开卷减闭卷的差值置信区间都跨零。Strict 模式的必要性结论不变，但泄漏幅度在这份噪声标签上一直不大。
- 局限：同一厂商同一系列、每组只运行一次；其他厂商的模型需要另外的 API key。