

LUAD Top-10 多智能体证据审阅 (v1)

后续对本版 65 条引文所做的[来源与药物指向预筛](#)将 23 条列为需要进一步核对；该结果不改写这里的冻结分级。

这是文献分诊 (**literature triage**)，不是疗效证据。分级只描述在 PubMed 中检索到、并且通过引用校验的文献现状，用来安排后续研究的优先级；不构成治疗建议，也不证明任何候选药物对肺腺癌有效。

运行日期:2026-09-28。模型:deepseek-flash(DeepSeek beta 端点,strict function calling)。代码:src/drug_repurposing_agent/multi_agent_review.py;运行器:scripts/run_multi_agent_review.py。结果:benchmark/results/multi_agent_review_v1.json。入口 trace: artifacts/multi_agent_review/traces/; 每次模型请求的 trace: artifacts/multi_agent_review/provider_traces/ (均被 git 忽略)。输入: configs/luad_top10_evidence_v1.json, 其 SHA-256 记录在结果中。

流程

- Literature Agent:**沿用现有的 PubMedClient(NCBI E-utilities,限速 0.36 s),并扩展了 ESearch ID 检索和 EFetch 摘要获取。检索式为 "< 药名 >[Title/Abstract] AND (lung adenocarcinoma OR non-small cell lung cancer OR NSCLC OR A549)",按相关度取前 8 篇,只保留有摘要的记录。这个 Agent 提出支持性论断,每条论断都必须对应一个 PMID,并附上摘要中的原句。
- Critic Agent:**另做一次检索,在同样的药名和肺癌词之外,再加上 resistance/toxicity/adverse/"no effect"/"did not"/failed/worse/reduced/survival 等负面词。对于糖皮质激素类候选药(通路中含 glucocorticoid),还会补充一次共享的类别级检索(糖皮质激素/地塞米松 + NSCLC + 耐药/免疫治疗,取前 5 篇)。Critic 要对每一条已验证的支持论断给出 stands/weakened/refuted 的判断,并列出反证,反证同样要附原文引用。
- 确定性校验器:**引用的 PMID 必须出现在该 Agent 实际检索到的记录集合中;引用句在空白归一化后,必须是该 PMID 摘要的逐字子串,且长度至少 20 个字符。不合格的论断会被丢弃并计数。Critic 引用的、不存在的 claim_id 也会被丢弃。
- Coordinator Agent:**从 {SUPPORTED, PROMISING_BUT_INCOMPLETE, CONFLICTING, INSUFFICIENT_EVIDENCE} 中选出一个分级,并写一段简短理由(strict JSON)。之后执行确定性护栏,护栏只能降级:没有任何已验证的支持论断时一律为 INSUFFICIENT_EVIDENCE;SUPPORTED 至少需要 2 个未被驳斥、候选药物本身范围内的 PMID。如果某个候选药物既没有检索到记录,也没有任何论断,就直接判为 INSUFFICIENT_EVIDENCE,不调用模型。

结果

排名 1 · hydrocortisone

- 支持检索命中 / 有摘要: 61 / 8
- 已验证支持论断: 6
- **Critic** 判定: 6 条均为 weakened
- 已验证反证: 6
- 多智能体分级: INSUFFICIENT_EVIDENCE

- 现有单轮结论: insufficient_evidence

排名 2 · beclomethasone-dipropionate

- 支持检索命中 / 有摘要: 7 / 7
- 已验证支持论断: 6
- **Critic** 判定: 5 条 weakened, 1 条 stands
- 已验证反证: 7
- 多智能体分级: INSUFFICIENT_EVIDENCE
- 现有单轮结论: insufficient_evidence

排名 3 · clocortolone-pivalate

- 支持检索命中 / 有摘要: 0 / 0
- 已验证支持论断: 0
- **Critic** 判定: —
- 已验证反证: 4 (类别级)
- 多智能体分级: INSUFFICIENT_EVIDENCE
- 现有单轮结论: insufficient_evidence

排名 4 · mometasone

- 支持检索命中 / 有摘要: 6 / 6
- 已验证支持论断: 6
- **Critic** 判定: 6 条均为 weakened
- 已验证反证: 4
- 多智能体分级: INSUFFICIENT_EVIDENCE
- 现有单轮结论: insufficient_evidence

排名 5 · flumetasone

- 支持检索命中 / 有摘要: 0 / 0
- 已验证支持论断: 0
- **Critic** 判定: —
- 已验证反证: 3 (类别级)
- 多智能体分级: INSUFFICIENT_EVIDENCE
- 现有单轮结论: insufficient_evidence

排名 6 · BRD-K84203638

- 支持检索命中 / 有摘要: 0 / 0
- 已验证支持论断: 0
- **Critic** 判定: —
- 已验证反证: 0
- 多智能体分级: INSUFFICIENT_EVIDENCE (确定性判定, 未调用模型)
- 现有单轮结论: insufficient_evidence

排名 7 · hydrocortisone-hemisuccinate

- 支持检索命中 / 有摘要: 0 / 0

- 已验证支持论断: 0
- **Critic** 判定: —
- 已验证反证: 4 (类别级)
- 多智能体分级: INSUFFICIENT_EVIDENCE
- 现有单轮结论: insufficient_evidence

排名 8 · fluorometholone

- 支持检索命中 / 有摘要: 0 / 0
- 已验证支持论断: 0
- **Critic** 判定: —
- 已验证反证: 4 (类别级)
- 多智能体分级: INSUFFICIENT_EVIDENCE
- 现有单轮结论: insufficient_evidence

排名 9 · fluticasone

- 支持检索命中 / 有摘要: 24 / 8
- 已验证支持论断: 6
- **Critic** 判定: 4 条 weakened, 2 条 stands
- 已验证反证: 7
- 多智能体分级: INSUFFICIENT_EVIDENCE
- 现有单轮结论: insufficient_evidence

排名 10 · diflorasone

- 支持检索命中 / 有摘要: 0 / 0
- 已验证支持论断: 0
- **Critic** 判定: —
- 已验证反证: 2 (类别级)
- 多智能体分级: INSUFFICIENT_EVIDENCE
- 现有单轮结论: insufficient_evidence

与现有单轮结论的比较: 10/10 一致, 全部为 INSUFFICIENT_EVIDENCE。现有单轮结论来自 configs/luad_top10_evidence_v1.json 和 docs/luad_top10_evidence_matrix.md。没有任何一个分级是由护栏改出来的: 每个调用了模型的候选, Coordinator 给出的都已经是 INSUFFICIENT_EVIDENCE。

各候选的主要理由 (由 Coordinator 生成, 已经过校验):

- **hydrocortisone**: 检索到的支持记录几乎都是免疫检查点抑制剂相关的垂体炎/肾上腺功能不全个案报告, 氢化可的松在其中是替代治疗, 不涉及抗肿瘤作用。
- **beclomethasone-dipropionate、mometasone、fluticasone**: 支持论断全部来自 A549 细胞上的体外抗炎、转录抑制或 CYP3A5 诱导等替代指标, 没有任何 LUAD/NSCLC 抗肿瘤终点、动物实验或临床证据。
- 其余 6 个: 按确切药名没有检索到候选药本身的文献, 只有糖皮质激素类别级的负面信号 (免疫治疗干扰、耐药)。

幻觉引用拒绝率: 两个 Agent 共提出 65 条带引用的论断 (支持 24 条, 反证 41 条), 校验器拒绝 0 条 (0.0%)。在 strict 工具调用、并且把检索到的摘要全文提供给模型的前提下, DeepSeek 没有编造 PMID, 也没有改写引文。

调用量：共 22 次模型调用（4 个有支持文献的候选各 3 次 Literature+Critic+Coordinator，5 个只有类别级记录的候选各 2 次 Critic+Coordinator，BRD-K84203638 为 0 次），全部成功，0 次重试。共约 6.3 万 token，估算费用为 0.014 美元（off-peak）至 0.028 美元（peak）。PubMed 请求另计，不收费。

局限与观察

- **逐字引用不等于引用正确。**校验器只能保证引文确实存在于该 PMID 的摘要中，无法保证引文能支持对应的论断。人工抽查发现：Critic 曾把一篇关于柚皮素纳米载体的 A549 摘要（PMID 33249629）标为 fluticasone 的 candidate 级反证；多次把一条勘误声明（PMID 41376996, Published Erratum，摘要只有一句 “This corrects the article”）当作证据引用；还常用 “X 是安全/有益的” 这种稻草人式表述来写反证。所以反证数量不能当作真实的矛盾强度，下一步应该加入论断-引文蕴含（NLI）检查或人工复核。
- **检索式与既有矩阵不同。**hydrocortisone 在既有矩阵中的候选药本身文献（PMID 1533045、35676421）没有进入按相关度排序的前 8 篇；fluticasone 的预防性荟萃分析（PMID 35843928）也没有被检索到。beclomethasone 的两篇既有文献（12538830、24555085）都检索到了。这是一次有边界的检索快照，不能证明 “不存在证据”。
- 只按确切药名检索，没有扩展同义词、盐或酯形式；身份问题（立体化学、剂型歧义）只作为 Coordinator 的输入，没有经过化学层面的核验。
- 只用了一个模型，每个候选只跑一轮，结果没有做重复性检验。

复现

```
python scripts/run_multi_agent_review.py # 需要 .env 中的 DEEPSEEK_API_KEY;  
↪ 已完成的候选会从 artifacts/multi_agent_review/checkpoint_v1.jsonl 续跑
```